TPC-H performance measure

Keisuke Suzuki

2012 年 12 月 20 日

1 実験環境

- CPU : Xeon X7560 @ 2.27GHz x4
- Memory : 64GB
- DBMS : PostgreSQL 9.2
- RAID0 : iodrive x8 (chunk size = 64KB)
- 各テーブルの primary key 上に B-tree index を構築
- Scale Factor = 100
- shared buffer = 8GB
- 各クエリの実行時の状況を iostat と mpstat で 1 秒おきに監視

2 Query 1 by index scan on l_shipdate

2.1 random read microbenchmark

look-ahead を切った状態での IO 性能が乱れていたので、その原因を探る。
測定時の条件

- look-ahead (read-ahead): 0
- iosize: 8KB
- raw device access

2.1.1 With O_DIRECT flag

まず OS のバッファリングなどを切った状態でのアクセス時の性能を示す。

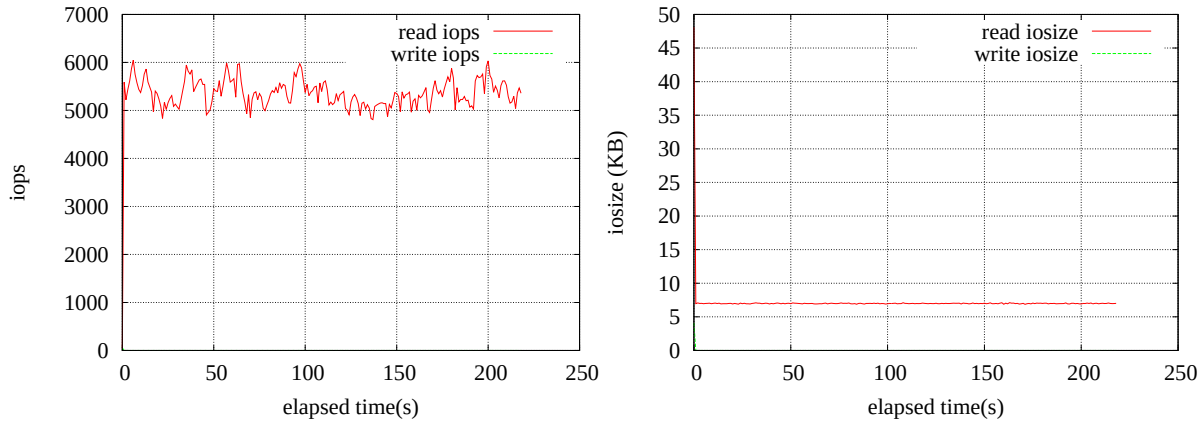

(a) IOPS　　(b) iosize

図 1　IO spec (iosize = 8KB)

表 1　IO spec average (iosize = 8KB)
(IOPS = (io issued by benchmark / elapsed time))

IOPS	MBPS
4578	37.5

benchmark 実行時の IO の発行状況を blktrace で監視すると以下の通りであった。

```
 9,0    1        1     0.000000000 38969  Q   R 1894937090 + 16 [randomread]
 9,0    1        2     0.000011450 38969  U   N [randomread] 0
 9,0    1        3     0.000331059 38969  Q   R 1645272306 + 13 [randomread]
 9,0    1        4     0.000338372 38969  Q   R 1645272319 + 3 [randomread]
 9,0    1        5     0.000339942 38969  X   R 1645272319 / 1645272320 [randomread]
 9,0    1        6     0.000347454 38969  U   N [randomread] 0
 9,0    1        7     0.000611996 38969  Q   R 2143216519 + 16 [randomread]
 9,0    1        8     0.000615720 38969  U   N [randomread] 0
  ...
CPU1 (md0):
Reads Queued:       1,172K,    7,882MiB Writes Queued:           0,        0KiB
Read Dispatches:        0,        0KiB  Write Dispatches:        0,        0KiB
Reads Requeued:         0               Writes Requeued:         0
Reads Completed:        0,        0KiB  Writes Completed:        0,        0KiB
Read Merges:            0,        0KiB  Write Merges:            0,        0KiB
Read depth:             0               Write depth:             0
IO unplugs:       1,000,000             Timer unplugs:           0

Throughput (R/W): 0KiB/s / 0KiB/s
Events (md0): 2,273,525 entries
```

2.1.2 Without O_DIRECT flag

O_DIRECT flag を使用しない状態でのアクセス時の性能を示す。

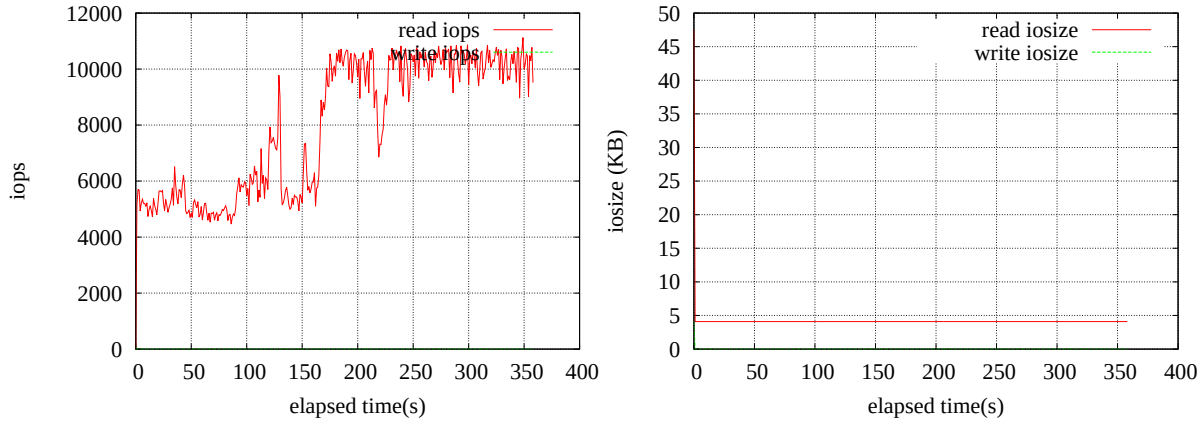

(a) IOPS　　(b) iosize

図 2　IO spec (iosize = 8KB)

表 2　IO spec average (iosize = 8KB)
(IOPS = (io issued by benchmark / elapsed time))

IOPS	MBPS
2787	22.8

図 2(b) を見ると、クエリ実行時と同様の性能の乱れが見られる。この乱れは、iodrive を OS の buffering を有効にして使用したときに生じる、デバイスの特性に由来するものではないかと考えられる。

また、iosize に着目すると、本来 8KB で IO を発行しているはずであるが、実際の IO は半分の 4KB で出ている。iostat で計測した IOPS と、benchmark で計算した IOPS も数値としてはあっていない。

そこで blktrace で benchmark 実行時の IO の発行状況を監視すると以下の通りであった。

```
  9,0    1        1     0.000000000 39618  Q   R 1894937088 + 8 [randomread]
  9,0    1        2     0.000009686 39618  U   N [randomread] 0
  9,0    1        3     0.000274736 39618  Q   R 1894937096 + 8 [randomread]
  9,0    1        4     0.000278264 39618  U   N [randomread] 0
  9,0    1        5     0.000503299 39618  Q   R 1894937104 + 8 [randomread]
  9,0    1        6     0.000509047 39618  U   N [randomread] 0
  9,0    1        7     0.000794094 39618  Q   R 1645272304 + 8 [randomread]
  9,0    1        8     0.000800924 39618  U   N [randomread] 0
  9,0    1        9     0.001145873 39618  Q   R 1645272312 + 8 [randomread]
  9,0    1       10     0.001152079 39618  U   N [randomread] 0
  ...
CPU1 (md0):
 Reads Queued:       2,860K,   11,442MiB Writes Queued:           0,        0KiB
 Read Dispatches:        0,        0KiB  Write Dispatches:        0,        0KiB
 Reads Requeued:         0               Writes Requeued:         0
 Reads Completed:        0,        0KiB  Writes Completed:        0,        0KiB
 Read Merges:            0,        0KiB  Write Merges:            0,        0KiB
 Read depth:             0               Write depth:             0
 IO unplugs:     2,860,599               Timer unplugs:           0

Throughput (R/W): 0KiB/s / 0KiB/s
Events (md0): 5,721,230 entries
```

この結果をみると、OS から発行される IO は 4KB のサイズになっている。これは OS がページサイズ単位 (4KB) に IO を分割して発行しているのではないかと考えられる。実際、他のサイズで IO を発行した場合も、OS からは 4KB の IO として発行されていることが確認できた。以下は、16KB のサイズでアクセスした場合の結果。

```
  9,0    1        1     0.000000000 39810  Q   R 1894937088 + 8 [randomread]
  9,0    1        2     0.000008815 39810  U   N [randomread] 0
  9,0    1        3     0.000352988 39810  Q   R 1894937096 + 8 [randomread]
  9,0    1        4     0.000359066 39810  U   N [randomread] 0
  9,0    1        5     0.000656633 39810  Q   R 1894937104 + 8 [randomread]
  9,0    1        6     0.000662659 39810  U   N [randomread] 0
  ...
CPU1 (md0):
 Reads Queued:       4,831K,   19,327MiB Writes Queued:           0,        0KiB
 Read Dispatches:        0,        0KiB  Write Dispatches:        0,        0KiB
```

```
 Reads Requeued:          0               Writes Requeued:         0
 Reads Completed:         0,        0KiB  Writes Completed:        0,        0KiB
 Read Merges:             0,        0KiB  Write Merges:            0,        0KiB
 Read depth:              0               Write depth:             0
 IO unplugs:      4,831,926               Timer unplugs:           0

Throughput (R/W): 0KiB/s / 0KiB/s
Events (md0): 9,663,852 entries
```